SPRAWOZDANIE: Zaawansowane techniki kryptografii i kryptoanalizy

Jakub Chrzanowski

Zadanie 1: Kryptoanaliza szyfru afinicznego

1. Wstęp

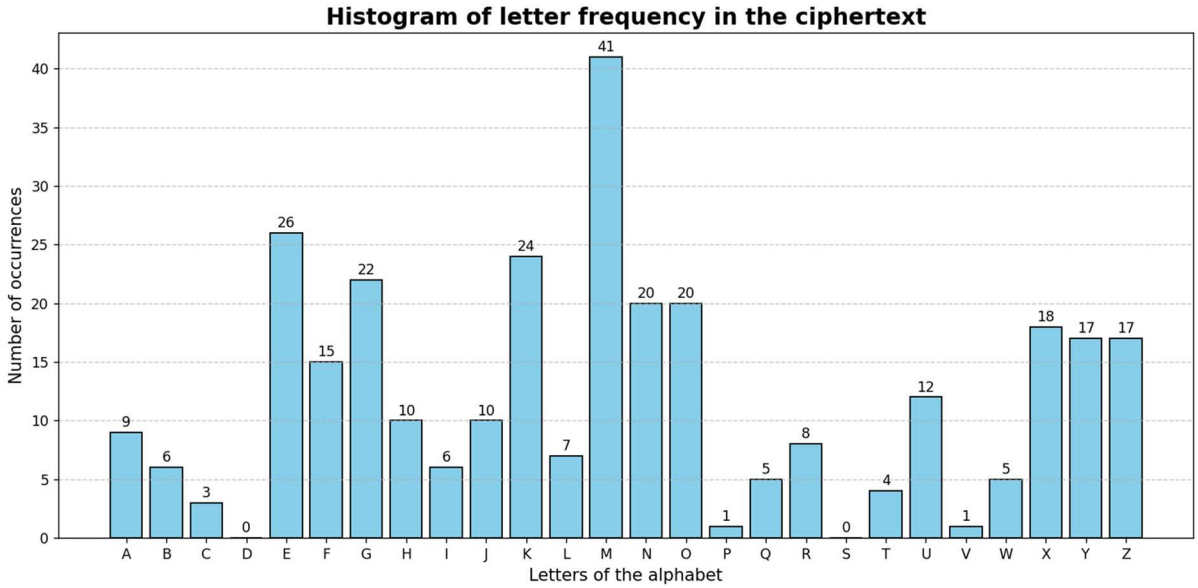
Celem zadania było przeprowadzenie kryptoanalizy szyfrogramu zaszyfrowanego szyfrem afinicznym o wzorze

$$e(x) = (ax + b) mod 26$$

Atak przeprowadzono metodą analizy częstości liter, opierając się na znajomości statystyki występowania liter w języku angielskim. Kryptoanalizę zaimplementowano w języku Python, a analizowany szyfrogram liczył 307 znaków.

2. Histogram częstości liter w szyfrogramie

Na podstawie dostarczonego szyfrogramu wygenerowano histogram częstości liter. Wizualizacja ta pozwala na szybkie zidentyfikowanie najczęściej występujących znaków, co jest fundamentem ataku statystycznego.



Zgodnie z załączonym wykresem oraz logami z terminala, rozkład najczęściej występujących liter w badanym kryptogramie przedstawia się następująco:

- M: 41 wystąpień
- E: 26 wystąpień
- K: 24 wystąpienia
- G: 22 wystąpienia
- N: 20 wystąpień

- O: 20 wystąpień

W języku angielskim najczęściej występującymi literami są kolejno: e, t, a, o, i, n. Podstawą kryptoanalizy jest formułowanie hipotez polegających na dopasowaniu "szczytów" z powyższego histogramu (M, E, K...) do statystycznie najczęstszych liter języka jawnego.

3. Obliczenia i testowanie hipotez (pary kluczy nieskutecznych)

Aby znaleźć klucz

$$(a, b)$$

, program rozwiązuje układ równań liniowych w ciele modulo 26, opierając się na parach najczęstszych liter.

Nie każda znaleziona para

$$(a, b)$$

jest poprawnym kluczem, ponieważ algorytm musi spełniać warunek odwracalności:

$$\gcd(a, 26) = 1$$

(Największy Wspólny Dzielnik liczby

$$a$$

i 26 musi wynosić 1).

```
================================================
AFFINE CIPHER CRYPTANALYSIS
================================================
Ciphertext (307 letters):
HEJJWIEEFHKGAOBMXHKYCMZGRENHAEEFKXFRKFLURJOYONWAEEFRMYKUGMVUGNKREUNMBMZWEXMZMQMQRMZGNHMGYMXMIHMZMGEQMEXMLJUAGKXOXYEXGLOY
UEUGAKFAMNOXNEKYEQLUNMZIKONGGMYEXFGKXFNKCMGEBMZNHMMXNOZMOXTZKGNZUYNUZMRKFRMYKUGMOXNHMZMKJIEZJFKFMBOYMFEMGXNHKYCMBMZWNHOX
AONKJIKWGMPLJEONGKGLMYOTOYLZENEYEJKFMGOAXTJKIEZKQOGYEXTOAUZMFFMBOYM

--- CIPHERTEXT HISTOGRAM ---
A:9 B:6 C:3 E:26 F:15 G:22 H:10 I:6 J:10 K:24 L:7 M:41 N:20 O:20 P:1 Q:5 R:8 T:4 U:12 V:1 W:5 X:18 Y:17 Z:17

Most frequent in ciphertext: ['M', 'E', 'K', 'G', 'N', 'O']
Most frequent in English   : ['e', 't', 'a', 'o', 'i', 'n']

--- TESTING HYPOTHESES ---
M=e, E=t: (a, b) = (22, 2) -> INVALID, GCD(22, 26) = 2
M=e, K=t: (a, b) = (12, 16) -> INVALID, GCD(12, 26) = 2
M=e, G=t: (a, b) = (10, 24) -> INVALID, GCD(10, 26) = 2

[+] FOUND AFFINE KEY: a=7, b=10
Plaintext:
hollywoodhasgivenhackersbothgoodandbadpublicitygoodbecausejustabouteveryoneremembersthescenewheresomeoneplugsaninconspic
uousgadgetintoacomputerwaitssecondsandtakesovertheentireinfrastructurebadbecauseintherealworldadevicedoesnthackeverythin
gitalwaysexploitsaspecificprotocoladesignflaworamisconfigureddevice
```

Zgodnie ze zrzutem z terminala program zidentyfikował i odrzucił następujące nieskuteczne (niedopuszczalne matematycznie) hipotezy:

1. Hipoteza: M = e oraz E = t
    - Z układu równań wynika klucz:

$$a = 22, b = 2$$

.

- Odrzucenie:

$$\gcd(22, 26) = 2 \neq 1$$

. Klucz niedopuszczalny (brak odwrotności modulo).

2. Hipoteza: M = e oraz K = t
   - Z układu równań wynika klucz:

$$a = 12, b = 16$$

.

- Odrzucenie:

$$\gcd(12, 26) = 2 \neq 1$$

. Klucz niedopuszczalny.

3. Hipoteza: M = e oraz G = t
   - Z układu równań wynika klucz:

$$a = 10, b = 24$$

.

- Odrzucenie:

$$\gcd(10, 26) = 2 \neq 1$$

. Klucz niedopuszczalny.

Program testuje również inne hipotezy, które mogą dawać poprawne matematycznie

$$a$$

(gdzie

$$\gcd = 1$$

), ale po rozszyfrowaniu tekst okazuje się zbiorem losowych znaków (wskaźnik podobieństwa do j. angielskiego jest poniżej progu). Zostają one wtedy odrzucone na rzecz poprawnego rozwiązania. Rozszyfrowując podany szyfrogram nie znaleziono takich kluczy.

4. Wybór ostatecznego klucza wraz z uzasadnieniem

Skrypt pomyślnie zidentyfikował i potwierdził poprawny klucz:
Klucz:

$$a = 7$$

,

$$b = 10$$

Uzasadnienie:

1. Warunek matematyczny:

$$\gcd(7, 26) = 1$$

. Liczba 7 ma swoją odwrotność modulo 26 (jest to liczba 15, ponieważ

$$7 \cdot 15 = 105 \equiv 1 mod 26$$

). Układ równań jest jednoznacznie odwracalny.

2. Sensowny tekst jawny: Po zastosowaniu funkcji deszyfrującej

$$d(y) = 15 \cdot (y - 10) mod 26$$

, uzyskano w pełni zrozumiały tekst w języku angielskim:

"hollywoodhasgivenhackersbothgoodandbadpublicitygoodbecausejustabouteveryoneremembersthescenewheresomeoneplugsaninconspicuousgadgetintoacomputerwaitssecondsandtakesovertheentireinfrastructurebadbecauseintherealworldadevicedoesnthackeverythingitalwaysexploitsaspecificprotocoladesignflaworamisconfigureddevice"
Tekst ten posiada wysoki wskaźnik prawdopodobieństwa występowania liter, co ostatecznie potwierdza poprawność złamanego klucza.

5. Dyskusja: Wpływ długości szyfrogramu na szybkość kryptoanalizy

Długość szyfrogramu ma kluczowy i bezpośredni wpływ na sukces oraz szybkość kryptoanalizy (analizy częstościowej):

- Długi szyfrogram (jak w analizowanym przypadku – 307 znaków) sprawia, że rozkład częstości liter zbliża się do idealnego rozkładu statystycznego dla danego języka (zgodnie z prawem wielkich liczb). Najczęstsze litery (takie jak 'e', 't', 'a') wyraźnie wybijają się na histogramie, co drastycznie zmniejsza liczbę hipotez do sprawdzenia. Właściwy klucz znajduje się niemal natychmiast.
- Krótki szyfrogram (np. poniżej 50 znaków) jest mocno podatny na anomalie statystyczne (np. w zdaniu o zebrach litera 'z' wystąpi częściej niż 'e'). W takim przypadku litera 'e' może nie być najczęstszym znakiem w szyfrogramie. Prowadzi to do konieczności przetestowania ogromnej liczby błędnych kombinacji, generowania tzw. "fałszywych trafień" i drastycznie wydłuża czas pracy (lub wręcz uniemożliwia w pełni automatyczne złamanie szyfru bez dodatkowej heurystyki i interwencji człowieka).

6. Dowód matematyczny

Teza: Funkcja szyfrująca

$$e(x) = (ax + b)mod26$$

musi być różnowartościowa (injekcja), aby szyfrowanie było odwracalne. Jest to równoważne warunkowi

$$\gcd(a, 26) = 1$$

.

Dowód:
Funkcja jest różnowartościowa, jeśli z faktu, że obrazy dwóch argumentów są równe, wynika, że same argumenty również są równe.
Załóżmy, że

$$e(x_1) = e(x_2) \pmod{26}$$

dla pewnych

$$x_1, x_2 \in \{0, 1, ., .25\}$$

.

$$ax_1 + b \equiv ax_2 + b \pmod{26}$$

Odejmując

$$b$$

obustronnie, otrzymujemy:

$$ax_1 \equiv ax_2 \pmod{26}$$

$$a(x_1 - x_2) \equiv 0 \pmod{26}$$

Powyższa kongruencja oznacza, że liczba 26 musi dzielić iloczyn

$$a \cdot (x_1 - x_2)$$

.

Przypadek 1 (warunek spełniony):

$$\gcd(a, 26) = 1$$

Skoro 26 i

$$a$$

są względnie pierwsze (nie mają wspólnych dzielników poza 1), to z twierdzenia o podzielności wynika, że liczba 26 musi w całości dzielić czynnik

$$(x_1 - x_2)$$

.
Ponieważ

$$x_1, x_2 \in \{0, 1, ., .25\}$$

, to różnica

$$(x_1 - x_2)$$

może wynosić wielokrotność 26 (np. 0, 26, -26) tylko i wyłącznie wtedy, gdy

$$x_1 - x_2 = 0$$

.
Zatem

$$x_1 = x_2$$

. Funkcja jest różnowartościowa i odwracalna.

Przypadek 2 (warunek niespełniony):

$$\gcd(a, 26) = d > 1$$

Oznacza to, że

$$a$$

oraz 26 mają wspólny dzielnik. Możemy zapisać

$$a = d \cdot k$$

oraz

$$26 = d \cdot m$$

(gdzie

$$1 < m \leq 26$$

).
Wybierzmy dwa różne znaki (liczby)

$$x_1$$

i

$$x_2$$

takie, że

$$x_1 - x_2 = m$$

. (Jest to możliwe, bo

$$m \leq 26$$

).
Podstawiając do równania:

$$a(x_1 - x_2) = (d \cdot k) \cdot m = k \cdot (d \cdot m) = k \cdot 26$$

Otrzymana wartość

$$k \cdot 26$$

jest z definicji podzielna przez 26 (reszta z dzielenia wynosi 0).
Zatem

$$a(x_1 - x_2) \equiv 0 \pmod{26}$$

, co oznacza, że

$$e(x_1) = e(x_2)$$

pomimo tego, że

$$x_1 \neq x_2$$

.
Dwa różne znaki tekstu jawnego zostaną zaszyfrowane na ten sam znak szyfrogramu (powstaje kolizja). Funkcja nie jest różnowartościowa, a proces nie jest odwracalny.

Tym samym dowiedziono, że warunek odwracalności (różnowartościowości) jest matematycznie równoważny z warunkiem

$$\gcd(a, 26) = 1$$